

Materia: Modelado de IA Aplicada

Proyecto: Prototipo-ML-para-Clasificación-de-Tickets-de-Soporte

1 - El Problema

El proyecto nace de una necesidad crítica en el departamento de atención al cliente que es la saturación provocada por la gestión manual de correos y consultas diarias. Actualmente, el proceso depende de operadores que deben leer, categorizar y derivar cada mensaje uno por uno, lo que no solo consume tiempo valioso, sino que impacta directamente en la satisfacción de los clientes. El objetivo central de nuestro proyecto es desarrollar un modelo capaz de automatizar la categorización y derivación de estas consultas, reemplazando el proceso manual.

2 - La Solución IA

Para resolver esta problemática, se propuso un modelo de **aprendizaje supervisado** enfocado en la **clasificación**. La elección del algoritmo **Random Forest** (Bosque Aleatorio) es estratégica, ya que este método es reconocido por su robustez al manejar grandes volúmenes de datos y su capacidad para procesar simultáneamente texto, variables numéricas y categóricas. Al utilizar un conjunto de árboles de decisión, el modelo reduce el riesgo de sobreajuste y garantiza una mayor precisión al identificar patrones en los correos electrónicos, facilitando la predicción de variables clave como el departamento de destino y el tipo de ticket.

Hemos considerados en evaluar otros modelos como Regresión Logística o SVM, ya que primero debemos analizar qué modelo procesa mejor la combinación de texto libre y datos categóricos presentes en los correos electrónicos.

3 - Los Datos

Nuestro trabajo iniciará tomando los datos en formato CSV para aplicar preprocesamiento de lenguaje natural (NLP) sobre el texto de los tickets. La viabilidad técnica del proyecto se apoya en un dataset sólido que ya existe y que cuenta con más de 28.000 registros.

Como Variables de Entrada (feature), procesaremos fundamentalmente las columnas de texto en idioma inglés dado que nuestro dataset es multilingüe (inglés y alemán), **Subject (asunto)**, **Body_Text (cuerpo del correo)** y **Problem_Type (tipo de problema)**. Por otro lado, las Variables de Salida (targets) serán etiquetas como **Departament (área de derivación)**, **Priority (prioridad del caso)**, **Ticket_Type (tipo de ticket** por ejemplo si es un incidente o petición) y **Tag_type** (con qué **tipo de producto** se relaciona la petición o incidente; por ejemplo, un incidente con un producto defectuoso o problemas para iniciar sesión en una cuenta)

4 - Arquitectura del Sistema

La arquitectura del sistema está pensada para ser escalable y accesible, operando de manera centralizada en la **nube** y exponiéndose a través de una **API REST** (Interfaz de programación de aplicaciones que utiliza el protocolo HTTP para permitir que diferentes aplicaciones web se comuniquen entre sí) que alimentará una aplicación web.

5 - Interfaz

La implementación se concibe como un sistema centralizado en la nube, exponiéndose a través de una aplicación web donde los empleados interactúan mediante formularios o texto libre (si

necesitan escribir por ejemplo el nombre de una categoría o buscar un correo en específico por palabras escritas). El sistema no solo entrega un resultado, sino que muestra un semáforo de confianza. Para que el operador sepa cuándo confiar plenamente en la sugerencia del modelo o cuándo el ticket requiere una revisión manual más exhaustiva, optimizando así la transparencia de la IA en el entorno laboral.

6 - Riesgos y Limites

A pesar de la factibilidad del modelo creemos que con el dataset elegido, no se podría predecir el estado emocional del cliente basado en el cuerpo del correo. El riesgo más crítico identificado es la clasificación errónea de prioridades, donde un asunto urgente podría quedar relegado al final de la lista; para mitigar esto, se contempla el uso de mensajes de advertencia y errores visibles

7 - Privacidad y Ética

Hemos verificado que los datos utilizados para el entrenamiento no contienen información sensible relacionada con la salud, finanzas o identidad de los usuarios. El acceso a la herramienta y a los datos estará restringido a los desarrolladores y al equipo de atención al cliente de la empresa y a sus stakeholders, garantizando que el almacenamiento de la información cumpla con los estándares de seguridad necesarios mientras el modelo optimiza los procesos administrativos.

Avance del Proyecto (resumen):

Durante el análisis exploratorio inicial del dataset filtrado solo con los correos en inglés (emails_ingles.csv) se encontró que muchas clases, de las variables objetivo *type*, *priority* y *queue* estaban considerablemente desbalanceadas; lo que podría generar que el modelo clasifique erróneamente las clases minoritarias como mayoritarias por el peso que estas obtuviesen.

Antes de tratar con ese inconveniente, se realizó una Lematización de los emails concatenados (subject + body_text) para reducir la dimensionalidad de los datos y que el modelo resultase mas preciso y evitar que el sistema trate variaciones gramaticales de una misma palabra como conceptos distintos. Luego se procedió con la vectorización de las palabras ya lematizadas.

Para corregir que el modelo realice clasificaciones erróneas, se decidió utilizar SMOTE (añadiendo datos sintéticos para las clases minoritarias y así balancear el dataset) durante el entrenamiento del modelo justo después de la división de datos para el mismo y evitar el sobremuestreo. Además, se entrenó tanto un modelo con Random Forest + SMOTE y un modelo SVM + SMOTE por separado porque son buenas para el procesamiento de lenguaje natural. Una vez hecho eso se realizó una comparación entre ambos modelos y resulto mejor en métricas Random Forest, además de ser considerablemente más rápido que SVM. Luego se obtuvo los archivos .pkl de cada variable objetivo y del vectorizador.